소량 라벨 환경에서 특징 기반 능동학습을 활용한 금속 표면 결함 객체 탐지

석사학위논문 심사용 수정본

2026년 9월

경북대학교 데이터사이언스대학원

데이터사이언스학과

이 호 열

지도교수 최 재 경

국문초록

금속 표면 결함 객체 탐지 모델을 학습하려면 결함의 위치와 종류가 표시된 라벨 데이터가 필요하다. 그러나 산업 현장에서 결함 이미지를 확보하고 각 결함에 경계 상자를 작성하는 작업에는 많은 시간과 비용이 든다. 능동학습은 라벨이 없는 데이터 중 학습에 유용한 표본을 우선 선택하여 제한된 라벨 데이터로 모델을 학습하는 방법이다. 본 연구에서는 사전학습된 DINOv2에서 추출한 이미지 특징을 이용한 표본 선택이 소량 라벨 환경에서 금속 표면 결함 객체 탐지 성능을 향상시킬 수 있는지 검증하였다.

실험에는 금속 표면 결함 데이터셋인 GC10-DET와 NEU-DET를 사용하였다. 사전학습된 DINOv2-small의 이미지 특징과 코사인 거리를 이용하여 현재 라벨 집합에서 가장 먼 이미지를 순차적으로 추가하는 방법(DINOv2-FF)을 무작위 선택(Random) 및 탐지 결과의 클래스 점수 엔트로피를 이용한 선택(Entropy)과 비교하였다. 라벨 이미지는 학습셋의 약 10%에서 35%까지 다섯 단계에 걸쳐 늘렸으며, 각 단계에서 YOLOv8n을 동일한 사전학습 가중치에서 새로 학습하였다. 데이터셋별로 5개의 선택 시드와 하나의 고정 학습 시드를 사용하였다. 개발셋으로 선택한 총 162개 모델을 최종평가셋에서 평가하고, mAP50-95 학습곡선, 정규화 학습곡선 아래 면적(nAULC), 클래스별 AP 및 선택된 이미지의 클래스 구성을 분석하였다.

GC10-DET에서 DINOv2-FF의 평균 nAULC는 Random보다 1.47%p, Entropy보다 1.92%p 높았으며, 두 비교 모두 다섯 선택 시드에서 차이가 양수였다. NEU-DET에서는 Random 대비 평균 차이가 0.30%p로 작고 시드별 방향이 달랐으며, Entropy 대비 0.51%p의 양의 평균 차이는 다섯 시드에서 모두 관찰되었다. 네 주 비교 모두 Holm 보정 후 통계적 유의성은 확인되지 않았다. R5의 클래스별 AP 차이는 GC10-DET의 welding_line에서 +11.32%p, NEU-DET의 inclusion에서 -1.37%p였으며, NEU-DET의 최저 클래스 nAULC는 DINOv2-FF가 Random보다 1.64%p 낮았다.

개발셋에서 관찰된 네 주 비교의 평균 차이 방향은 최종평가셋에서도 유지되었다. 그러나 특징 기반 다양성 선택의 평균적 이점은 데이터셋에 따라 달랐고, 모든 결함 클래스와 최저 클래스 성능의 향상으로 이어지지는 않았다.

주제어: 금속 표면 결함, 객체 탐지, 능동학습, DINOv2, 이미지 특징 기반 표본 선택

목차

Ⅰ 서론 1
1.1 연구 배경과 필요성 1
1.2 문제 정의 1
1.3 연구 목적과 연구 질문 2
1.4 연구 범위와 기여 2
1.5 논문 구성 3
Ⅱ 관련 연구 3
2.1 금속 표면 결함 객체 탐지 3
2.2 객체 탐지를 위한 능동학습 3
2.3 불확실성 기반 표본 선택 4
2.4 특징 공간의 다양성 기반 표본 선택과 DINOv2 4
2.5 본 연구의 위치 5
Ⅲ 연구 방법 5
3.1 전체 연구 설계 5
3.2 데이터셋과 데이터 분할 6
3.3 라벨 이미지 비율과 능동학습 절차 7
3.4 표본 선택 방법 7
3.4.1 Random 8
3.4.2 DINOv2 특징 기반 다양성 선택 8
3.4.3 불확실성 기반 선택(Entropy) 8
3.5 YOLOv8n 학습 조건 9
3.6 반복 실험 설계 9
3.7 평가 지표와 통계 분석 10
Ⅳ 연구 결과 12
4.1 실험 결과 개요 12
4.2 GC10-DET의 라벨 이미지 비율별 학습 성능 12
4.3 NEU-DET의 라벨 이미지 비율별 학습 성능 13
4.4 nAULC와 통계 결과 14
4.5 전체 학습자료 참고 결과 15
4.6 클래스별 성능과 선택 구성 15
4.7 개발셋과 최종평가셋의 비교 18
Ⅴ 논의 19
5.1 데이터셋에 따라 달라진 데이터 선택 효과 19
5.2 클래스별 선택 구성과 탐지 성능 19
5.3 Entropy와 Random 비교 결과 20
5.4 특징 기반 다양성 선택의 해석 20
5.5 연구의 한계와 향후 연구 21
Ⅵ 결론 22
참고문헌 23
ABSTRACT 25
부록 A 재현을 위한 실행 조건 26

그림 및 표 목록

표 2-1. 관련 연구와 본 연구의 비교 관점 5
표 3-1. 최종 실험의 데이터 구성 6
표 3-2. 단계별 누적 라벨 이미지 수와 비율 7
표 3-3. 탐지 모델의 주요 학습 조건 9
그림 4-1. 라벨 이미지 비율에 따른 최종평가셋 학습곡선 12
표 4-1. 라벨 예산별 최종평가셋 mAP50-95 13
표 4-2. 최종평가셋 nAULC 14
표 4-3. DINOv2-FF의 대응 nAULC 차이와 검정 결과 14
표 4-4. 전체 학습자료 참고값과 R5 평균 성능 15
그림 4-2. 최종평가셋 R5에서 DINOv2-FF와 Random의 클래스별 AP50-95 차이 15
표 4-5. GC10-DET 전체 클래스의 R5 성능 16
표 4-6. GC10-DET 클래스별 누적 선택 이미지 수 16
표 4-7. NEU-DET 전체 클래스의 R5 성능 17
표 4-8. NEU-DET 클래스별 누적 선택 이미지 수 17
표 4-9. 개발셋과 최종평가셋의 대응 nAULC 차이 18
표 A-1. 특징 추출과 표본 선택의 세부 조건 26
표 A-2. 학습과 통계의 추가 설정 26
표 A-3. 최종평가 환경과 실행 조건 26

Ⅰ 서론

1.1 연구 배경과 필요성

금속 표면의 결함을 정확하게 탐지하는 것은 제조 공정의 품질관리를 위해 중요하다. 같은 종류의 결함이라도 크기와 형태가 다르고, 촬영 환경이나 표면 상태에 따라 영상에서 보이는 모습도 달라질 수 있다. 이러한 특성을 처리하기 위해 금속 표면 결함 탐지 연구는 사람이 영상 특징을 직접 설계하는 방식에서 딥러닝을 이용해 특징을 학습하는 방식으로 발전해 왔다[1,2].

객체 탐지는 이미지에 결함이 존재하는지를 판단하는 것뿐 아니라 결함의 위치와 종류를 함께 예측한다. 이를 위해서는 각 결함의 위치를 경계 상자로 표시하고 해당 결함의 종류를 지정한 학습자료가 필요하다. 충분한 학습자료를 확보할수록 다양한 결함을 학습할 수 있지만, 실제로 많은 이미지를 수집하고 각각의 결함을 라벨링하는 데에는 상당한 시간과 비용이 요구된다.

능동학습(Active Learning)은 이러한 라벨링 부담을 줄이기 위해 전체 데이터 중 학습에 유용한 표본을 우선적으로 선택하는 방법이다[3]. 초기 라벨 데이터로 모델을 학습한 뒤 아직 라벨이 없는 후보에서 일부 이미지를 선택하고, 새로 확보한 라벨을 추가하여 모델을 다시 학습하는 과정을 반복한다. 객체 탐지에서도 이러한 방식으로 주석 대상 이미지를 선택하는 연구가 진행되어 왔으며[4], 금속 표면 결함 탐지에 적용한 사례도 보고되었다[5].

능동학습의 성능은 어떤 기준으로 다음 이미지를 선택하느냐에 따라 달라질 수 있다. 일반적으로 현재 모델이 판단하기 어려워하는 표본을 선택하거나, 기존 학습자료와 다른 특징을 가진 표본을 추가하는 방법 등이 사용된다. 특히 최근에는 대규모 이미지로 사전학습된 모델에서 얻은 특징을 이용하여 라벨 없이도 이미지 사이의 유사도와 차이를 계산할 수 있게 되었다[6].

본 연구에서는 이러한 사전학습 이미지 특징을 표본 선택에 이용한다. DINOv2에서 추출한 특징을 이용하여 현재 선택된 이미지와 시각적으로 다른 표본을 추가하고, 이러한 선택 방식이 실제 금속 표면 결함 객체 탐지 모델의 학습 성능에 어떤 영향을 주는지 확인하고자 하였다.

1.2 문제 정의

능동학습에서 널리 사용되는 방법 중 하나는 현재 학습 중인 모델의 예측 결과를 이용하여 불확실한 표본을 선택하는 것이다[3,4]. 객체 탐지에서는 예측한 클래스 점수나 검출 결과를 이용해 이미지의 불확실성을 계산하고, 점수가 높은 이미지를 다음 학습자료로 추가할 수 있다. 이러한 방식은 현재 모델이 어려워하는 표본을 직접 반영할 수 있다는 장점이 있지만, 선택 결과가 학습 중인 모델의 상태에 영향을 받는다.

다른 방법은 이미지의 특징 공간에서 기존에 선택된 자료와 다른 표본을 추가하는 것이다. Sener와 Savarese는 제한된 수의 표본으로 전체 데이터의 특징 공간을 대표하도록 선택하는 core-set 방식을 능동학습에 적용하였다[7]. 최근에는 DINOv2와 같은 대규모 사전학습 모델이 별도의 추가 학습 없이도 이미지의 시각적 특징을 제공하므로[6], 이를 이용하여 현재 탐지 모델의 예측과 별개로 후보 이미지 사이의 차이를 계산할 수 있다.

그러나 특징 공간에서 서로 다른 이미지를 선택하는 것과 실제 객체 탐지 성능을 높이는 것은 같은 문제가 아니다. 특징 거리에는 결함의 종류뿐 아니라 배경, 표면 상태, 결함의 크기와 형태 등 여러 시각적 요소가 함께 반영될 수 있다. 따라서 특징 공간에서 다양한 이미지를

확보했다고 하더라도 그 선택이 탐지 모델의 학습에 어느 정도 도움이 되는지는 실제 학습 결과를 통해 확인할 필요가 있다.

또한 전체 평균 성능만으로 표본 선택 방법의 효과를 판단하기 어려운 경우가 있다. 선택 기준에 따라 특정 결함을 포함한 이미지가 더 많이 선택되거나 적게 선택될 수 있으며, 그 결과 클래스별 성능 변화가 전체 평균과 다른 방향으로 나타날 수 있다. 이에 본 연구에서는 전체 성능과 함께 클래스별 탐지 성능과 선택된 데이터의 구성을 분석한다.

1.3 연구 목적과 연구 질문

본 연구의 목적은 소량 라벨 환경에서 사전학습 이미지 특징을 이용한 다양성 기반 표본 선택이 금속 표면 결함 객체 탐지 성능에 미치는 영향을 확인하는 것이다. 이를 위해 DINOv2 특징을 이용한 표본 선택 방법을 무작위 선택 및 탐지 모델의 불확실성을 이용한 선택 방법과 비교하였다.

성능은 특정 라벨 예산에서의 결과뿐 아니라 라벨 데이터가 증가하는 전체 과정에서 비교하였다. 약 10%에서 35%까지 라벨 이미지를 단계적으로 늘리고 각 단계의 mAP50-95를 측정하였으며, 전체 학습곡선은 정규화 학습곡선 아래 면적(nAULC)으로 요약하였다. 클래스별 AP와 선택된 이미지의 클래스 구성도 함께 분석하였다.

이를 바탕으로 다음 두 가지 연구 질문을 설정하였다.

RQ1. 소량 라벨 환경에서 무작위 선택(Random), DINOv2 특징 기반 다양성 선택(DINOv2-FF), 불확실성 기반 선택(Entropy)은 금속 표면 결함 객체 탐지 성능에서 어떠한 차이를 보이는가?

RQ2. 표본 선택 방법에 따른 성능 차이는 데이터셋과 결함 클래스별로 어떻게 나타나며, 선택된 이미지의 클래스 구성과는 어떠한 관계를 보이는가?

첫 번째 연구 질문은 라벨 예산별 mAP50-95와 nAULC를 이용하여 세 표본 선택 방법의 학습 성능을 비교한다. 두 번째 연구 질문에서는 전체 평균에서 나타난 차이를 클래스별 성능과 선택 데이터의 구성으로 나누어 살펴본다.

1.4 연구 범위와 기여

실험에는 금속 표면 결함 데이터셋인 GC10-DET와 NEU-DET를 사용하였다. 표본 선택 방법은 Random, DINOv2-FF, Entropy의 세 가지이며, 탐지 모델은 YOLOv8n으로 통일하였다. 각 데이터셋에서 초기 라벨 집합을 약 10%로 구성한 뒤 다섯 차례의 표본 선택을 거쳐 약 35%까지 라벨 이미지를 증가시켰다.

표본 선택에 따른 변동을 확인하기 위해 데이터셋별로 5개의 선택 시드를 사용하였다. 탐지 모델의 학습 시드는 하나로 고정하였으므로, 반복 실험 간 변동은 초기 라벨 집합과 표본 선택 경로의 차이에서 비롯된다. 전체 실험에서 학습한 탐지 모델은 162개이다.

본 연구의 기여는 다음과 같다. 첫째, 사전학습 특징 기반 다양성 선택을 금속 표면 결함 객체 탐지에 적용하여, 동일한 이미지 수 예산과 탐지 모델 조건에서 무작위 선택 및 불확실성 기반 선택과 비교한 결과를 두 공개 데이터셋에 대해 제시하였다. 둘째, 약 10%에서 35%까지의 학습곡선 전체를 nAULC로 요약하고, 선택 시드 단위의 대응 비교로 방법 간 차이를

평가하였다. 셋째, 전체 클래스의 AP와 선택된 이미지의 클래스 구성을 함께 제시하여 평균 성능의 차이가 결함 클래스별로 어떻게 나뉘는지를 보였다.

1.5 논문 구성

본 논문은 총 6장으로 구성하였다. Ⅰ장에서는 연구 배경과 문제를 설명하고 연구 목적과 연구 질문을 제시한다. Ⅱ장에서는 금속 표면 결함 객체 탐지, 능동학습, 불확실성 기반 선택 및 특징 공간의 다양성을 이용한 표본 선택에 관한 선행연구를 검토한다.

Ⅲ장에서는 사용한 데이터셋과 데이터 분할, 라벨 예산, 표본 선택 방법, YOLOv8n의 학습 조건 및 평가 방법을 설명한다. Ⅳ장에서는 GC10-DET와 NEU-DET에서 수행한 실험 결과를 라벨 예산별 성능, nAULC, 클래스별 성능 및 선택 데이터의 구성으로 나누어 제시한다. Ⅴ장에서는 실험 결과의 의미를 데이터셋과 결함 클래스의 차이를 중심으로 논의하고 연구의 한계와 향후 연구 방향을 다룬다. 마지막으로 Ⅵ장에서는 연구 결과를 요약하고 연구 질문에 대한 결론을 제시한다.

Ⅱ 관련 연구

2.1 금속 표면 결함 객체 탐지

금속 표면 결함을 자동으로 검사하는 연구에는 이미지 단위의 결함 종류를 판별하는 분류, 결함의 위치와 종류를 함께 찾는 객체 탐지, 결함 영역을 픽셀 단위로 구분하는 분할 등이 있다. 이 가운데 객체 탐지는 이미지에 포함된 결함의 종류뿐 아니라 위치까지 예측하므로, 학습을 위해 결함의 클래스와 경계 상자 정보가 함께 필요하다.

Song과 Yan[2]은 열간 압연 강판의 표면 결함을 분류하기 위한 NEU 데이터셋과 특징 기술 방법을 제시하였다. 이후 딥러닝 기반의 특징 학습이 널리 사용되면서 금속 표면 결함의 위치를 직접 탐지하는 연구도 확대되었다. Lv 등[1]은 10종의 금속 표면 결함을 포함하는 GC10-DET 데이터셋을 제시하고, 이를 이용한 객체 탐지 성능을 평가하였다.

금속 표면 결함의 탐지 성능을 높이기 위한 연구는 크게 탐지 모델의 구조나 특징 표현을 개선하는 방향과 학습에 사용할 데이터를 효과적으로 구성하는 방향으로 나누어 볼 수 있다. 본 연구는 후자의 문제에 초점을 두며, 동일한 탐지 모델과 학습 조건에서 어떤 이미지를 학습자료로 선택하느냐에 따라 성능이 어떻게 달라지는지를 살펴본다.

2.2 객체 탐지를 위한 능동학습

능동학습은 라벨이 없는 데이터 가운데 학습에 유용한 표본을 선택하여 추가로 라벨을 확보하는 방법이다[3]. 일반적으로 초기 라벨 집합으로 모델을 학습한 뒤, 남아 있는 데이터에서 새로운 표본을 선택하고 이를 기존 학습자료에 추가하는 과정을 반복한다.

객체 탐지에서는 하나의 이미지에 여러 객체가 포함될 수 있기 때문에 어떤 단위를 라벨 예산으로 사용할 것인지가 중요하다. 이미지 한 장 전체를 선택할 수도 있고 개별 객체나 경계 상자를 선택 단위로 사용할 수도 있다. Aghdam 등[4]은 객체 탐지에서 이미지 단위의 표본

선택과 순차적인 능동학습 과정을 다루었다. 금속 표면 결함 분야에서 Lv 등[5]은 예측 클래스 확률의 마진으로 불확실한 이미지를 선택하고 결함 클래스별 선택 비율을 조정하는 방법을 제안하였으며, NEU-DET의 네 개 클래스로 구성한 부분집합에서 Random, Entropy, 마진 기반 선택과 비교하였다.

라벨 예산을 정의하는 방법도 연구마다 차이가 있다. Lyu 등[10]은 이미지 단위와 경계 상자 단위의 주석량을 구분하여 객체 탐지 능동학습을 평가하였고, Pardo 등[11]은 서로 다른 주석 방식에 따른 비용을 고려하였다. 본 연구에서는 실험 과정에서 선택된 이미지 수를 라벨 예산으로 사용한다. 이는 각 표본 선택 방법이 동일한 수의 이미지를 사용할 때 탐지 성능이 어떻게 달라지는지를 비교하기 위한 것이다.

2.3 불확실성 기반 표본 선택

불확실성 기반 선택은 현재 학습된 모델이 판단하기 어려워하는 표본을 우선적으로 선택하는 방법이다. 분류 문제에서는 가장 높은 클래스 확률이나 상위 클래스 간 확률 차이, 예측 엔트로피 등이 불확실성 지표로 사용되어 왔다[3].

객체 탐지에서는 한 이미지에서 여러 개의 예측 박스가 생성되기 때문에 불확실성을 이미지 단위의 선택 점수로 변환하는 과정이 추가로 필요하다. 예측 박스별 클래스 점수를 이용할 경우 어떤 박스를 포함할 것인지, 여러 박스의 점수를 어떻게 하나의 이미지 점수로 합칠 것인지에 따라 표본의 선택 순서가 달라질 수 있다.

불확실성 기반 방법은 현재 탐지 모델이 어려워하는 이미지를 선택 과정에 직접 반영할 수 있다는 장점이 있다. 반면 초기 라벨 데이터가 적은 상황에서는 모델의 예측 자체가 충분히 안정되지 않았을 수 있으며, 탐지되지 않은 객체의 정보는 예측 박스만을 이용한 불확실성 점수에 충분히 반영되지 않을 가능성이 있다.

Gupte 등[8]은 DINOv2와 OpenCLIP 같은 기반 모델의 표현이 초기 라벨 집합 선택, 다양성 확보, 대표성 기반 선택과 불확실성 기반 선택 사이의 절충이라는 능동학습의 세 요소에 미치는 영향을 이미지 분류 과제에서 평가하였다. Yang 등[9]은 객체 탐지에서 불확실성과 다양성을 함께 이용하는 표본 선택 방법을 제안하였다.

본 연구에서는 두 기준의 효과를 구분하여 살펴보기 위해 탐지 모델의 클래스 예측 점수를 이용한 Entropy와 사전학습 이미지 특징의 다양성을 이용한 DINOv2-FF를 각각 비교 방법으로 구성하였다.

2.4 특징 공간의 다양성 기반 표본 선택과 DINOv2

다양성 기반 표본 선택은 현재 라벨 집합에 충분히 포함되지 않은 특징을 가진 데이터를 추가하는 데 목적이 있다. Sener와 Savarese[7]는 능동학습의 표본 선택을 제한된 수의 대표 표본으로 전체 데이터의 특징 공간을 표현하는 core-set 문제로 정의하고, 기존 선택 집합에서 멀리 떨어진 표본을 순차적으로 추가하는 방법을 제시하였다.

이러한 방법에서는 이미지 사이의 거리를 어떤 특징 공간에서 계산하는지가 중요하다. 최근의 사전학습 이미지 모델은 대규모 이미지 데이터를 이용해 학습한 시각 특징을 제공하며, 새로운 데이터에 대해 별도의 추가 학습 없이 특징 벡터를 추출할 수 있다. DINOv2는

자기지도학습을 이용해 학습된 이미지 특징을 제공하며 다양한 시각 인식 과제에서 활용되고 있다[6].

다만 Gupte 등[8]의 실험은 이미지 분류를 대상으로 하였으며, 사전학습 특징 공간의 다양성 선택이 산업 결함 객체 탐지 모델의 학습 성능으로 이어지는지는 다루지 않았다.

2.5 본 연구의 위치

기존 연구에서는 객체 탐지를 위한 능동학습, 불확실성을 이용한 표본 선택, 특징 공간의 다양성을 이용한 core-set 방식, 사전학습 시각 특징을 이용한 능동학습 등이 각각 연구되어 왔다. 산업 결함 분야에서도 능동학습을 적용하여 라벨링할 데이터를 선택하는 연구가 이루어지고 있다.

그러나 사전학습 특징 기반 다양성 선택을 금속 표면 결함 객체 탐지에 적용하여 불확실성 기반 선택과 같은 조건에서 비교하고, 그 결과를 결함 클래스별 성능과 선택 구성까지 나누어 보고한 연구는 본 연구에서 검토한 범위에서는 찾기 어려웠다.

이에 본 연구에서는 GC10-DET와 NEU-DET를 대상으로 Random, DINOv2-FF 및 Entropy를 동일한 YOLOv8n 학습 조건에서 비교하였다. 약 10%에서 35%까지의 라벨 예산에서 성능 변화를 추적하고, 전체 학습곡선과 클래스별 성능, 선택된 이미지의 클래스 구성을 함께 분석하였다.

표 2-1. 관련 연구와 본 연구의 비교 관점

연구	주요 내용	본 연구와의 관계
Aghdam 등[4]	객체 탐지의 이미지 단위 능동학습	객체 탐지에서 이미지 단위 표본 선택 절차 참고
Lv 등[5]	금속 표면 결함 탐지의 불확실성 기반 능동학습	산업 결함 객체 탐지에 능동학습을 적용한 선행연구
Sener와 Savarese[7]	특징 공간의 core-set 선택	DINOv2-FF의 다양성 선택 절차와 관련
Gupte 등[8]	사전학습 시각 특징을 이용한 능동학습	특징 표현과 초기 라벨 집합에 따른 선택 성능 비교
Yang 등[9]	객체 탐지에서 불확실성과 다양성 결합	객체 탐지에서 두 선택 기준을 함께 활용한 사례
Lyu 등[10], Pardo 등[11]	주석 단위와 라벨 예산	이미지 수 기준 예산과 실제 주석 비용의 차이 참고
본 연구	금속 표면 결함 객체 탐지에서 세 표본 선택 방법 비교	라벨 예산별 성능, 클래스별 성능 및 선택 구성을 함께 분석

Ⅲ 연구 방법

3.1 전체 연구 설계

본 연구는 라벨이 제한된 상황에서 표본 선택 방법에 따라 금속 표면 결함 객체 탐지 성능이 어떻게 달라지는지를 비교하였다. 비교 방법은 무작위 선택(Random), DINOv2 특징을 이용한 다양성 선택(DINOv2-FF), 탐지 모델의 예측 불확실성을 이용한 Entropy의 세 가지이다.

실험에는 GC10-DET와 NEU-DET를 사용하였다. 각 데이터셋을 학습셋, 개발셋, 최종평가셋으로 나누고, 학습셋에서 능동학습을 수행하였다. 초기에는 학습셋의 약 10%만

라벨이 있는 것으로 설정하였으며, 이후 다섯 차례에 걸쳐 표본을 추가하여 최종적으로 약 35%까지 라벨 데이터를 늘렸다.

세 방법은 같은 초기 라벨 집합에서 시작하며, 각 단계에서 추가할 이미지를 선택하는 기준만 다르게 적용하였다. 선택이 끝난 뒤에는 누적된 라벨 이미지를 이용하여 YOLOv8n을 동일한 초기 가중치에서 새로 학습하였다. 이를 통해 이전 단계의 학습 이력이 다음 단계에 누적되지 않도록 하고, 표본 선택 방법에 따른 차이를 비교하였다.

학습 과정에서 저장할 모델은 개발셋의 성능을 기준으로 결정하였다. 최종평가에서는 이렇게 선택한 모델과 평가 조건 및 분석 방법을 고정한 뒤, 별도로 분리해 둔 최종평가셋(test)에서 성능을 측정하였다. 본 논문의 주 성능 결과와 통계 비교는 최종평가셋에 근거하며, 개발셋 결과는 관찰된 차이의 방향을 비교하는 보조 자료로 제시한다. 최종평가셋은 표본 선택, 학습 및 저장 모델 선택에 사용하지 않았다.

3.2 데이터셋과 데이터 분할

실험에는 금속 표면 결함 객체 탐지 데이터셋인 GC10-DET[1]와 NEU-DET[2]를 사용하였다. GC10-DET의 원 논문은 10개 결함 클래스, 3,570장의 이미지를 제시하였다[1]. 본 연구에서 확보한 GC10-DET 배포본은 이미지 경로 2,312개와 XML 주석 2,294개로 구성되었으며, 이를 정제하여 2,291장을 사용하였다. NEU-DET는 6개 결함 클래스, 1,800장으로 구성되며[2], 정제 후 1,798장을 사용하였다.

데이터는 학습셋, 개발셋, 최종평가셋으로 분리하였으며 목표 비율은 70:15:15로 정하였다. GC10-DET는 학습셋 1,604장, 개발셋 343장, 최종평가셋 344장으로 구성하였고, NEU-DET는 각각 1,258장, 270장, 270장으로 구성하였다(표 3-1).

표 3-1. 최종 실험의 데이터 구성

데이터셋	클래스 수	전체	학습셋	개발셋	최종평가셋
GC10-DET	10	2291	1604	343	344
NEU-DET	6	1798	1258	270	270

단위는 이미지 수(장)이다.

데이터 분할은 이미지 단위가 아니라 서로 관련된 이미지를 묶은 연결요소 단위로 수행하였다. GC10-DET에서는 동일 이미지, 검증된 파일명 관계, 내용상 관련된 이미지를 연결한 연결요소를, NEU-DET에서는 동일 이미지와 내용상 중복으로 판정된 이미지를 연결한 연결요소를 하나의 분할 단위로 사용하였다. 그 결과 GC10-DET 953개, NEU-DET 756개의 연결요소가 구성되었으며, 서로 다른 분할에 걸친 연결요소는 없었다.

학습셋은 표본 선택과 탐지 모델 학습에, 개발셋은 저장 모델 선택과 개발 과정의 성능 확인에 사용하였다. 최종평가셋은 모델과 분석 절차를 고정한 뒤 최종 성능 평가에 사용하였다. 평가 전 이미지 식별자, 파일 및 RGB 해시와 연결요소를 기준으로 분할 간 중복이 없음을 다시 확인하였다.

3.3 라벨 이미지 비율과 능동학습 절차

라벨 이미지 비율은 각 데이터셋의 학습셋에서 선택된 이미지의 수로 정의하였다. 이미지 한 장이 선택되면 해당 이미지에 포함된 모든 객체의 클래스와 경계 상자 정보를 학습에 사용하였다.

초기 단계는 R0으로 정의하고 이후 다섯 번의 추가 선택 단계를 R1부터 R5로 구분하였다. 목표 라벨 비율은 10%, 15%, 20%, 25%, 30%, 35%이며, 각 비율을 실제 이미지 수로 변환하여 누적 선택 수를 결정하였다.

누적 이미지 수 n_r은 학습셋 크기를 N, 라운드를 r=0,…,5 라고 할 때 다음과 같이 계산하였다.

$$n_r = \left\lfloor \frac{N(10+5r)+50}{100} \right\rfloor$$

이에 따른 실제 이미지 수와 비율은 표 3-2와 같다.

표 3-2. 단계별 누적 라벨 이미지 수와 비율

단계	GC10 이미지 수	GC10 비율(%)	NEU 이미지 수	NEU 비율(%)
R0	160	9.975	126	10.016
R1	241	15.025	189	15.024
R2	321	20.012	252	20.032
R3	401	25.000	315	25.040
R4	481	29.988	377	29.968
R5	561	34.975	440	34.976

GC10-DET의 분모는 1,604장, NEU-DET의 분모는 1,258장이다.

R0의 초기 라벨 집합은 각 선택 시드에 따라 무작위로 구성하였다. 같은 데이터셋과 같은 선택 시드에서는 Random, DINOv2-FF, Entropy가 동일한 R0에서 시작하도록 하였다.

각 라운드는 **추가 이미지 선택 → 누적 라벨 집합 구성 → YOLOv8n 학습 → 개발셋 평가**의 순서로 진행하였다. 한 번 선택한 이미지는 이후 라운드에서도 학습자료에 포함하며 다시 선택하지 않았다. 후보 이미지의 정답 라벨은 표본 선택 과정에서 사용하지 않고, 선택이 완료된 뒤 해당 이미지의 학습에만 사용하였다.

3.4 표본 선택 방법

세 방법은 추가할 이미지를 결정하는 기준만 다르게 구성하였다. Random은 남아 있는 후보에서 이미지를 무작위로 선택하고, DINOv2-FF는 사전학습 이미지 특징의 거리를 이용한다. Entropy는 현재 탐지 모델이 예측한 클래스 점수의 불확실성을 이용한다.

3.4.1 Random

Random은 아직 선택되지 않은 후보 이미지에서 필요한 수만큼 균등하게 비복원 추출하였다. 모든 후보가 동일한 선택 확률을 가지며 이미지의 특징이나 탐지 모델의 예측 결과는 사용하지 않았다.

초기 라벨 집합인 R0 역시 같은 방식으로 생성하였다. 각 선택 시드에서는 세 방법이 동일한 R0를 공유하며, 이후 라운드부터 각 방법의 선택 결과가 달라진다. 초기 집합을 구성할 때 클래스 정보를 이용한 별도의 층화 추출은 적용하지 않았다.

3.4.2 DINOv2 특징 기반 다양성 선택

DINOv2-FF는 현재 라벨 집합과 특징이 다른 이미지를 우선적으로 추가하는 방법이다. 특징 추출에는 사전학습된 DINOv2-small을 사용하였으며, 금속 표면 결함 데이터로 모델을 추가 학습하지 않고 고정된 상태에서 특징을 추출하였다.

입력 이미지는 원본의 가로세로 비율을 유지하면서 긴 변을 518픽셀로 조정하였다. 이후 이미지를 중앙에 배치하고 남은 영역을 채워 518×518 크기의 입력을 구성하였다. 이 과정에서는 원본 이미지의 일부를 잘라내지 않았다.

각 이미지는 DINOv2-small의 마지막 정규화를 거친 클래스 토큰에서 얻은 384차원 벡터로 표현하였다. 특징 벡터에는 L2 정규화를 적용하고, 두 이미지 사이의 차이는 코사인 거리로 계산하였다. 정규화된 두 특징 벡터를 z_i, z_j라 하면 거리는 다음과 같다.

$$d(i,j)=1-z_i^T z_j$$

표본 선택에는 가장 먼 표본부터 추가하는 방식(farthest-first)을 사용하였다[7]. 후보 이미지 x와 현재 라벨 집합 L 사이의 거리는 후보에서 가장 가까운 기존 이미지까지의 거리로 정의하였다.

$$s(x) = \min_{l \in L} d(z_x, z_l)$$

3.4.3 불확실성 기반 선택(Entropy)

Entropy는 현재 탐지 모델이 클래스 구분을 어려워하는 이미지를 우선적으로 선택하기 위한 비교 방법이다. 먼저 각 후보 이미지에 대해 탐지 결과를 생성하고, 비최대 억제(non-maximum suppression)를 적용한 뒤 남은 예측 박스의 클래스 점수에서 엔트로피를 계산하였다.

박스 b의 클래스 c에 대한 시그모이드 점수를 s(b,c), 클래스 수를 C라고 하면, 먼저 점수의 합이 1이 되도록 다음과 같이 정규화하였다.

$$q_{bc}=\frac{s_{bc}}{\sum_{k=1}^{C} s_{bk}}$$

이후 박스의 정규화 엔트로피를 계산하였다.

$$H_b = -\frac{\sum_{c=1}^{C} q_{bc}\log(q_{bc})}{\log(C)}$$

한 이미지의 선택 점수는 남아 있는 예측 박스들의 엔트로피 평균으로 정하였다. 탐지된 박스가 없는 이미지에는 0을 부여하였다.

선택용 추론에는 최대 클래스 점수가 0.25를 넘는 박스를 사용하였다. 비최대 억제의 IoU 기준은 0.70, 이미지당 최대 검출 수는 300으로 설정하였다. R1에서는 공통 R0 모델을 사용하고, R2부터 R5까지는 직전 Entropy 라운드에서 학습한 모델을 이용하여 남아 있는 후보를 다시 평가하였다.

3.5 YOLOv8n 학습 조건

표본 선택 방법 이외의 영향을 줄이기 위해 탐지 모델은 모든 실험에서 YOLOv8n[13]으로 통일하였다. 각 라운드의 모델은 이전 라운드에서 학습한 가중치를 이어받지 않고 동일한 공개 사전학습 가중치에서 새로 학습하였다.

주요 학습 조건은 표 3-3과 같다.

표 3-3. 탐지 모델의 주요 학습 조건

항목	설정
탐지 모델과 초기화	YOLOv8n, 모든 학습에서 동일한 공개 사전학습 가중치 사용
학습 길이와 입력	100 에포크, 조기 종료 대기 100, 입력 크기 640, 배치 크기 8
최적화	SGD, 초기 학습률 0.01, 최종 학습률 비율 0.01, 모멘텀 0.937, 가중치 감쇠 0.0005
학습 초기 조정	준비 구간 3 에포크, 준비 구간 모멘텀 0.8, 편향 학습률 0.1
주요 증강	색조·채도·명도 변형, 이동 0.1, 크기 변형 0.5, 수평 반전 확률 0.5, 모자이크 1.0
증강 종료	마지막 10 에포크에서 모자이크 비활성화
학습 재현 조건	학습 시드 2026091900 고정, 결정적 연산 설정, 혼합 정밀도 학습 사용
개발셋 재평가 및 최종평가	입력 크기 640, 배치 크기 8, 점수 기준 0.001, IoU 0.70, 최대 검출 수 300

회전, 전단, 원근 변형, 수직 반전, mixup, cutmix 및 copy_paste는 적용하지 않았다. 세부 증강값과 실행 환경은 부록 A에 제시하였다.

학습 중에는 개발셋의 성능을 기준으로 저장 모델을 선택하였다. 선택된 모델의 개발셋 재평가와 최종평가셋 평가는 표 3-3의 동일한 평가 조건으로 수행하였다. Entropy 선택용 추론의 점수 기준(0.25)은 성능 평가의 점수 기준(0.001)과 별도로 설정하였다. 최종평가 전에 기존 모델 한 개로 개발셋 평가값의 일치를 확인하였으며, 최종평가 환경과 검증 범위는 부록 A에 제시하였다.

3.6 반복 실험 설계

초기 라벨 집합과 이후 표본 선택 과정에서 발생하는 변동을 확인하기 위해 각 데이터셋에서 다섯 개의 선택 시드를 사용하였다. 선택 시드는 2026091901부터 2026091905까지이며, 탐지 모델 학습에는 2026091900을 고정 학습 시드로 사용하였다.

같은 선택 시드에서는 세 표본 선택 방법이 동일한 초기 라벨 집합에서 시작한다. 따라서 방법 간 비교는 같은 선택 시드끼리 대응시켜 수행하였다. 반복 실험에서 달라지는 부분은 초기 라벨 집합과 이후 표본 선택 경로이며, 탐지 모델 학습에 사용하는 난수 초깃값은 동일하게 유지하였다.

본실험은 데이터셋별로 공통 R0 모델 5개, Random의 R1~R5 모델 25개, DINOv2-FF 25개, Entropy 25개, 전체 학습자료 참고 모델 1개로 구성하였다. 데이터셋당 81개이며 두 데이터셋에서 총 162개의 모델을 학습하였다.

3.7 평가 지표와 통계 분석

객체 탐지의 주 성능 지표는 mAP50-95로 설정하였다. mAP50-95는 예측 박스와 정답 박스 사이의 IoU 기준을 0.50부터 0.95까지 0.05 간격으로 변화시키며 계산한 평균 정밀도(AP)를 전체 클래스에 대해 요약한 값이다[12]. 결과는 백분율로 표시하고, 방법 간 차이는 퍼센트포인트(%p)로 나타냈다.

라벨 예산에 따른 성능 변화는 최종평가셋의 학습곡선으로 나타내었다. 가로축은 각 단계에서 사용한 실제 누적 라벨 이미지 수 또는 학습셋 대비 비율이며 세로축은 mAP50-95이다. 같은 방법과 라운드에서 다섯 선택 시드의 평균을 사용하고 표본 표준편차를 함께 제시하였다.

약 10%에서 35%까지의 전체 라벨 예산 구간을 하나의 값으로 비교하기 위해 정규화 학습곡선 아래 면적(nAULC)을 사용하였다. 선택 시드 i, 방법 a에서 라운드 r의 라벨 이미지 수를 n_r, mAP50-95를 m(i,a,r)이라고 하면 학습곡선 아래 면적은 다음과 같이 계산하였다.

$$AULC_{i,a} = \sum_{r=0}^{4} \frac{m_{i,a,r} + m_{i,a,r+1}}{2} (n_{r+1} - n_r)$$

이를 관측한 라벨 예산 범위로 나누어 nAULC를 계산하였다.

$$nAULC_{i,a} = \frac{AULC_{i,a}}{n_5 - n_0}$$

전체 학습자료를 사용한 참고 모델의 성능으로 다시 나누지는 않았다.

방법 간 통계 비교에서는 같은 선택 시드에서 얻은 nAULC의 대응 차이를 사용하였다. 예를 들어 DINOv2-FF와 Random의 차이는 다음과 같다.

$$\Delta_i = nAULC_{i,\mathrm{DINO}} - nAULC_{i,\mathrm{Random}}$$

대응 차이의 95% 구간은 선택 시드를 복원추출하는 백분위수 부트스트랩[15]을 100,000회 수행하여 계산하였다. 방법 간 검정에는 정확 양측 부호반전 검정(exact two-sided sign-flip test)을 사용하였으며, 선택 시드가 다섯 개이므로 가능한 2^5=32개의 부호 조합을 모두

계산하였다. 이 경우 얻을 수 있는 최소 p값은 0.0625이므로, 검정 결과보다 대응 차이의 크기와 방향이 일치한 시드 수를 중심으로 결과를 해석하였다.

주 비교는 각 데이터셋에서 DINOv2-FF와 Random, DINOv2-FF와 Entropy의 차이로 정하고 네 비교에 Holm 보정[14]을 적용하였다. Entropy와 Random의 차이는 보조 비교로 제시하였다.

클래스별 분석에서는 R5의 AP50-95와 선택된 이미지의 클래스 구성을 함께 확인하였다. 한 이미지에 두 개 이상의 클래스가 포함된 경우 각 클래스의 포함 이미지 수에 각각 반영하였다. 또한 각 라운드에서 AP가 가장 낮은 클래스의 AP를 이어 최저 클래스 학습곡선을 구성하고, 이 곡선의 nAULC를 보조 지표로 계산하였다. 최저 클래스는 라운드마다 달라질 수 있다.

이상의 지표, 네 주 비교, 부트스트랩 횟수 및 검정 절차는 최종평가셋의 결과를 확인하기 전에 고정하였다. 부트스트랩 구간은 고정된 학습 시드와 데이터 분할에서 선택 시드에 따른 변동을 나타내며, 새로운 학습 시드나 평가 이미지 표본에 따른 불확실성을 모두 포함하지는 않는다.

IV 연구 결과

4.1 실험 결과 개요

두 데이터셋에서 학습한 탐지 모델은 공통 R0 모델 10개, Random 50개, DINOv2-FF 50개, Entropy 50개, 전체 학습자료 참고 모델 2개로 총 162개이다. 최종평가에서는 기록된 SHA-256과 일치하는 162개 모델을 각각 한 번 평가하였다. 공통 R0는 세 방법이 같은 평가값을 공유하며, 기술 점검용 모델은 분석 대상에서 제외하였다.

본 장에서는 GC10-DET 344장과 NEU-DET 270장으로 구성된 최종평가셋의 결과를 제시한다. 세 표본 선택 방법은 같은 선택 시드에서 동일한 R0로 시작하였으며, 이후 R1부터 R5까지 서로 다른 이미지를 추가하였다. 성능은 라벨 예산별 mAP50-95, nAULC, 클래스별 AP와 선택된 이미지의 클래스 구성을 중심으로 비교하였다. 개발셋과의 비교는 4.7절에서 별도로 제시한다.

4.2 GC10-DET의 라벨 이미지 비율별 학습 성능

GC10-DET의 R0 평균 mAP50-95는 16.91%였다. 이후 R1부터 R5까지 DINOv2-FF의 평균 성능은 모든 라벨 예산에서 Random과 Entropy보다 높게 나타났다.

R1에서 Random과 DINOv2-FF의 평균 성능은 각각 17.93%와 19.06%였으며, R2에서는 18.63%와 20.34%였다. R5에서는 Random 21.71%, DINOv2-FF 23.28%, Entropy 21.78%로 나타났다. R5에서 DINOv2-FF와 Random의 평균 차이는 1.57%p였다.

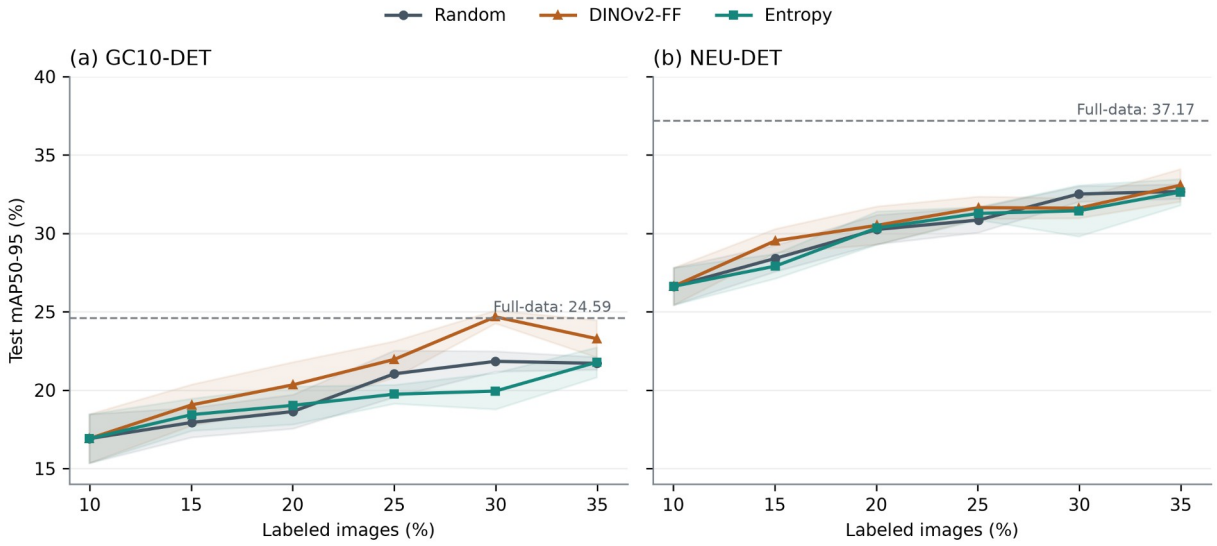


그림 4-1. 라벨 이미지 비율에 따른 최종평가셋 학습곡선. 왼쪽은 GC10-DET, 오른쪽은 NEU-DET이다. 값은 선택 시드 5개의 평균 ± 표본 표준편차이며, 점선은 전체 학습자료 참고 모델 1개의 성능이다.

4.3 NEU-DET의 라벨 이미지 비율별 학습 성능

NEU-DET에서는 세 방법의 평균 성능 차이가 GC10-DET보다 작게 나타났다. R0의 평균 mAP50-95는 26.62%였으며, R1에서는 Random 28.40%, DINOv2-FF 29.52%, Entropy 27.91%였다.

DINOv2-FF는 R1, R2, R3 및 R5에서 세 방법 중 가장 높은 평균 성능을 보였다. R4에서는 Random 32.51%, DINOv2-FF 31.61%로 Random의 평균이 높았다. R5의 성능은 Random 32.67%, DINOv2-FF 33.06%, Entropy 32.63%였다.

따라서 NEU-DET에서는 DINOv2-FF가 여러 라벨 예산에서 높은 평균값을 보였지만, 모든 예산에서 일관되게 가장 높지는 않았다. 시드별 차이와 전체 예산 구간의 결과는 nAULC의 대응 비교로 확인하였다.

표 4-1. 라벨 예산별 최종평가셋 mAP50-95

자료	단계	이미지 수	Random	DINOv2-FF	Entropy
GC10	R0	160	16.91 ± 1.56	16.91 ± 1.56	16.91 ± 1.56
	R1	241	17.93 ± 0.94	19.06 ± 1.31	18.44 ± 1.03
	R2	321	18.63 ± 1.08	20.34 ± 1.46	19.03 ± 1.21
	R3	401	21.04 ± 1.49	21.96 ± 1.16	19.74 ± 0.60
	R4	481	21.83 ± 0.65	24.67 ± 0.41	19.94 ± 1.16
	R5	561	21.71 ± 0.40	23.28 ± 1.19	21.78 ± 0.96
NEU	R0	126	26.62 ± 1.19	26.62 ± 1.19	26.62 ± 1.19
	R1	189	28.40 ± 0.84	29.52 ± 0.76	27.91 ± 0.79
	R2	252	30.24 ± 0.93	30.51 ± 1.22	30.34 ± 1.06
	R3	315	30.85 ± 0.79	31.64 ± 0.71	31.27 ± 0.41
	R4	377	32.51 ± 0.50	31.61 ± 0.64	31.44 ± 1.63
	R5	440	32.67 ± 0.46	33.06 ± 1.04	32.63 ± 0.84

단위는 %이며 평균 ± 표본 표준편차(n=5)이다. 실제 라벨 비율은 표 3-2에 제시하였다. R0의 같은 평가값을 세 방법에 표시하였다.

4.4 nAULC와 통계 결과

라벨 예산별 성능을 전체 구간에서 비교하기 위해 R0부터 R5까지의 학습곡선을 nAULC로 요약하였다.

GC10-DET에서 Random의 평균 nAULC는 19.74%, DINOv2-FF는 21.21%, Entropy는 19.29%였다. DINOv2-FF는 Random보다 평균 1.47%p, Entropy보다 1.92%p 높게 나타났다.

NEU-DET에서는 Random 30.32%, DINOv2-FF 30.62%, Entropy 30.11%였다. DINOv2-FF와 Random의 평균 차이는 0.30%p, Entropy와의 차이는 0.51%p였다.

표 4-2. 최종평가셋 nAULC

데이터셋	Random	DINOv2-FF	Entropy
GC10-DET	19.74 ± 0.66	21.21 ± 0.80	19.29 ± 0.35
NEU-DET	30.32 ± 0.41	30.62 ± 0.52	30.11 ± 0.67

평균 ± 표본 표준편차(n=5), 단위 %. 차이는 반올림 전의 대응 결과에 근거한다.

표 4-3. DINOv2-FF의 대응 nAULC 차이와 검정 결과

자료와 비교	차이(%p)	95% 구간	양수 시드	정확 p	Holm p
GC10 DINOv2-FF−Random	1.47	0.94 ~ 1.95	5/5	0.0625	0.2500
GC10 DINOv2-FF−Entropy	1.92	1.44 ~ 2.32	5/5	0.0625	0.2500
NEU DINOv2-FF−Random	0.30	-0.34 ~ 0.97	3/5	0.5625	0.5625
NEU DINOv2-FF−Entropy	0.51	0.19 ~ 0.84	5/5	0.0625	0.2500

95% 구간은 대응쌍의 백분위수 부트스트랩 구간이다. 정확 p는 양측 부호반전 검정이며 네 비교에 Holm 보정을 적용하였다.

GC10-DET에서는 DINOv2-FF와 Random의 대응 차이가 다섯 선택 시드에서 모두 양수였으며, DINOv2-FF와 Entropy의 비교에서도 같은 방향이 나타났다. 두 비교의 정확 양측 p값은 0.0625였고 Holm 보정 후 p값은 0.25였다.

NEU-DET에서 DINOv2-FF와 Random의 차이는 다섯 시드 중 세 개에서 양수였으며, 95% 구간은 0을 포함하였다. Entropy 대비 차이는 다섯 시드 모두에서 양수였고 95% 구간은 0보다 높았으나, 정확 양측 p값은 0.0625, Holm 보정 후 p값은 0.25였다. 네 주 비교 모두 유의수준 0.05에서 통계적 유의성은 확인되지 않았다.

보조 비교인 Entropy와 Random의 nAULC 차이는 GC10-DET에서 -0.45%p(95% 구간 -0.87~-0.10, 양수 시드 1/5, 정확 p=0.1250), NEU-DET에서 -0.21%p(95% 구간 -0.89~0.67, 양수 시드 2/5, 정확 p=0.6250)였다. 이 보조 비교에는 주 비교의 Holm 보정을 적용하지 않았다.

4.5 전체 학습자료 참고 결과

학습셋 전체를 사용한 참고 모델의 최종평가셋 mAP50-95는 GC10-DET 24.59%, NEU-DET 37.17%였다.

약 35%의 라벨 이미지를 사용한 R5에서 GC10-DET의 평균 성능은 Random 21.71%, DINOv2-FF 23.28%, Entropy 21.78%였다. NEU-DET에서는 각각 32.67%, 33.06%, 32.63%로 나타났다.

표 4-4. 전체 학습자료 참고값과 R5 평균 성능

자료	전체 자료 1회	R5 Random	R5 DINOv2-FF	R5 Entropy
GC10	24.59	21.71	23.28	21.78
NEU	37.17	32.67	33.06	32.63

최종평가셋 mAP50-95 (%). R5는 다섯 선택 시드의 평균이며 전체 자료 모델은 데이터셋별 1회 결과이다. 본문의 절대 차이는 반올림 전 수치에 근거한다.

GC10-DET에서 전체 학습자료 모델과 DINOv2-FF의 차이는 1.31%p였고 Random과의 차이는 2.88%p였다. NEU-DET에서 전체 학습자료 모델과 DINOv2-FF의 차이는 4.10%p였다. 전체 학습자료 결과는 단일 모델의 참고값이므로, 이를 성능의 상한이나 약 35% 라벨 사용의 동등성 근거로 해석하지 않았다.

4.6 클래스별 성능과 선택 구성

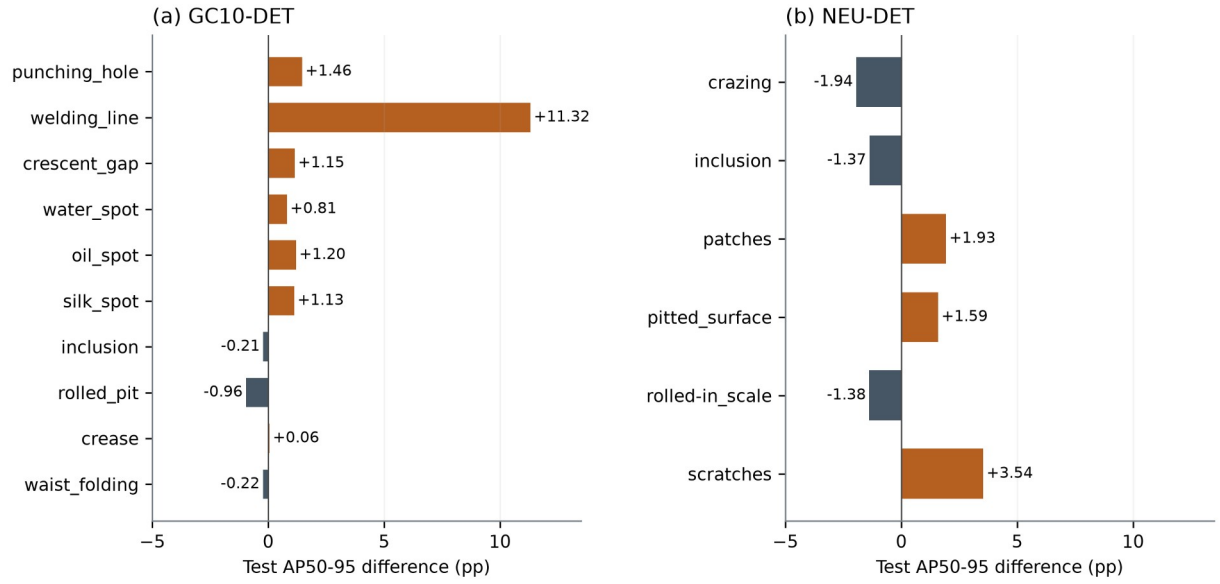


그림 4-2. 최종평가셋 R5에서 DINOv2-FF와 Random의 클래스별 AP50-95 차이. GC10-DET 10개와 NEU-DET 6개 클래스에 대한 선택 시드 5개의 평균 차이(%p)이다.

전체 평균 성능의 차이가 각 결함 클래스에서도 같은 방향으로 나타나는지 확인하기 위해 R5의 클래스별 AP50-95를 비교하였다.

GC10-DET에서는 클래스에 따라 차이의 크기와 방향이 달랐다. DINOv2-FF와 Random의 평균 차이는 welding_line에서 + 11.32%p로 가장 컸으며, punching_hole + 1.46%p, oil_spot + 1.20%p, silk_spot + 1.13%p 등이 양의 차이를 보였다. 반면 rolled_pit은 -0.96%p, waist_folding은 -0.22%p, inclusion은 -0.21%p였다(표 4-5).

선택된 이미지의 클래스 구성도 방법에 따라 차이가 있었다. 예를 들어 welding_line을 포함한 이미지의 평균 누적 선택 수는 Random 122.4장, DINOv2-FF 205.4장, Entropy 90.6장이었다. 반대로 silk_spot은 Random 180.2장, DINOv2-FF 98.0장, Entropy 102.0장으로 나타났다(표 4-6).

표 4-5. GC10-DET 전체 클래스의 R5 성능

클래스	Random	DINOv2-FF	Entropy	차이
punching_hole	45.77 ± 1.57	47.24 ± 1.65	48.57 ± 1.22	1.46
welding_line	30.69 ± 5.24	42.01 ± 7.89	28.32 ± 2.76	11.32
crescent_gap	51.94 ± 2.77	53.09 ± 1.96	49.29 ± 1.23	1.15
water_spot	30.34 ± 3.73	31.16 ± 3.98	29.39 ± 4.52	0.81
oil_spot	22.35 ± 2.44	23.55 ± 2.30	24.66 ± 2.18	1.20
silk_spot	2.53 ± 1.79	3.66 ± 3.37	3.91 ± 3.63	1.13
inclusion	3.03 ± 0.91	2.82 ± 0.75	3.51 ± 0.99	-0.21
rolled_pit	6.40 ± 3.49	5.44 ± 2.78	6.94 ± 2.80	-0.96
crease	8.08 ± 4.30	8.13 ± 4.64	11.40 ± 3.16	0.06
waist_folding	15.92 ± 4.24	15.70 ± 2.85	11.76 ± 2.56	-0.22

최종평가셋 AP50-95의 평균 ± 표본 표준편차(%), n=5. 마지막 열은 DINOv2-FF와 Random의 평균 차이(%p)이다. 차이는 반올림 전 값으로 계산하였다.

표 4-6. GC10-DET 클래스별 누적 선택 이미지 수

클래스	Random	DINOv2-FF	Entropy
punching_hole	78.4	113.2	66.8
welding_line	122.4	205.4	90.6
crescent_gap	61.6	101.4	49.4
water_spot	73.6	86.4	120.0
oil_spot	62.4	67.6	90.8
silk_spot	180.2	98.0	102.0
inclusion	52.0	34.2	99.8
rolled_pit	12.8	20.4	23.2
crease	13.6	26.6	25.2
waist_folding	36.4	17.0	12.0

R5에서 해당 클래스를 포함한 누적 선택 이미지 수의 시드 평균(장)이다. 같은 이미지에 여러 클래스가 있으면 각각에 포함되므로 클래스별 수의 합을 총 선택 이미지 수로 해석하지 않는다.

NEU-DET에서는 scratches + 3.54%p, patches + 1.93%p, pitted_surface + 1.59%p로 DINOv2-FF의 평균 AP가 Random보다 높았다. 반면 crazing은 -1.94%p, inclusion은 -1.37%p, rolled-in_scale은 -1.38%p로 낮았다.

선택 구성에서는 scratches를 포함한 이미지가 Random에서 평균 74.6장, DINOv2-FF에서 121.2장 선택되었다. 반대로 rolled-in_scale은 Random 74.4장에 비해 DINOv2-FF에서 32.8장으로 적게 선택되었다.

NEU-DET의 전체 클래스 결과와 선택 구성은 표 4-7, 표 4-8과 같다. 라운드별 최저 AP 클래스로 구성한 학습곡선의 nAULC는 NEU-DET에서 Random 12.01%, DINOv2-FF 10.37%, Entropy 12.58%였다. DINOv2-FF와 Random의 대응 차이는 -1.64%p였으며 다섯 시드 중 네 개에서 음수였다. GC10-DET에서는 각각 1.56%, 1.67%, 1.89%였고, DINOv2-FF와 Random의 차이는 0.10%p였다. 이는 각 모델·라운드에서 가장 낮은 클래스 AP를 취한 보조 지표로, 특정 클래스 하나의 고정된 성능 곡선과는 구별된다.

표 4-7. NEU-DET 전체 클래스의 R5 성능

클래스	Random	DINOv2-FF	Entropy	차이
crazing	13.13 ± 1.19	11.19 ± 2.60	14.02 ± 1.19	-1.94
inclusion	33.56 ± 2.05	32.19 ± 2.80	34.26 ± 3.77	-1.37
patches	50.25 ± 2.27	52.18 ± 2.00	50.05 ± 0.37	1.93
pitted_surface	35.31 ± 1.99	36.90 ± 3.03	36.19 ± 2.19	1.59
rolled-in_scale	25.66 ± 2.25	24.27 ± 4.63	25.72 ± 1.67	-1.38
scratches	38.11 ± 1.75	41.65 ± 2.56	35.52 ± 3.06	3.54

최종평가셋 AP50-95의 평균 ± 표본 표준편차(%), n=5. 마지막 열은 DINOv2-FF와 Random의 평균 차이(%p)이다. 차이는 반올림 전 값으로 계산하였다.

표 4-8. NEU-DET 클래스별 누적 선택 이미지 수

클래스	Random	DINOv2-FF	Entropy
crazing	70.8	31.0	102.4
inclusion	92.8	116.2	81.2
patches	80.8	86.2	92.6
pitted_surface	74.8	106.0	69.4
rolled-in_scale	74.4	32.8	76.6
scratches	74.6	121.2	59.4

R5에서 해당 클래스를 포함한 누적 선택 이미지 수의 시드 평균(장)이다. 같은 이미지에 여러 클래스가 있으면 각각에 포함되므로 클래스별 수의 합을 총 선택 이미지 수로 해석하지 않는다.

4.7 개발셋과 최종평가셋의 비교

표 4-9. 개발셋과 최종평가셋의 대응 nAULC 차이

자료	비교	개발셋	최종평가셋
GC10	DINOv2-FF−Random	1.83	1.47
GC10	DINOv2-FF−Entropy	1.95	1.92
NEU	DINOv2-FF−Random	0.09	0.30
NEU	DINOv2-FF−Entropy	0.16	0.51

단위는 %p이다. 같은 학습 모델을 두 평가셋에서 평가한 대응 차이의 평균이며, 별도의 재학습 반복실험을 의미하지 않는다.

네 주 비교에서 개발셋의 양의 평균 차이 방향은 최종평가셋에서도 유지되었다. GC10-DET에서는 DINOv2-FF가 Random과 Entropy보다 높은 평균 nAULC를 보였고, NEU-DET에서는 Random 대비 차이가 작았다. NEU-DET의 Entropy 대비 차이는 최종평가셋에서 다섯 선택 시드 모두 양수였으나, 네 주 비교 모두 Holm 보정 후 유의하지 않았다.

평균 차이의 방향이 같더라도 세부 결과가 모두 일치한 것은 아니다. NEU-DET에서 DINOv2-FF가 가장 높은 평균 성능을 보인 라운드는 개발셋의 R2·R3에서 최종평가셋의 R1·R2·R3·R5로 달라졌다. GC10-DET의 rolled_pit과 silk_spot, NEU-DET의 inclusion에서는 DINOv2-FF와 Random의 R5 AP 차이 방향이 바뀌었다. 따라서 개발셋의 경향이 최종평가셋에서 유지되었다는 해석은 주 비교의 평균 차이와 클래스별 결과를 구분하여 적용해야 한다.

Ⅴ 논의

5.1 데이터셋에 따라 달라진 데이터 선택 효과

최종평가셋에서도 DINOv2-FF의 평균적 이점은 데이터셋에 따라 달랐다. GC10-DET에서는 R1부터 R5까지 모든 라벨 예산에서 DINOv2-FF의 평균이 가장 높았으며, 개발셋에서 관찰된 방향이 유지되었다. NEU-DET에서는 Random 대비 평균 nAULC 차이가 작고 시드별 방향이 달랐다.

이러한 결과는 특징 기반 다양성 선택의 효과를 데이터셋의 특성과 함께 해석할 필요가 있음을 보여준다. DINOv2-FF는 현재 선택된 이미지와 특징 공간에서 멀리 떨어진 표본을 추가한다. 결함의 형태와 크기, 배경, 같은 클래스 안의 시각적 변화 등이 선택 결과에 영향을 줄 수 있으나, 본 실험은 이들 요인의 개별 효과를 분리하여 검증하지는 않았다.

GC10-DET에서는 다섯 선택 시드 모두에서 DINOv2-FF의 nAULC가 Random과 Entropy보다 높아, 이 결과가 특정 초기 라벨 집합에 한정된 것은 아니었다. 다만 대응쌍이 5개인 정확 검정의 최소 p값이 0.0625이므로, 방향의 일치를 통계적 유의성으로 해석할 수는 없다.

NEU-DET에서는 DINOv2-FF가 R1·R2·R3·R5에서 가장 높은 평균값을 보였지만 R4에서는 Random이 높았다. 전체 구간에서 Random 대비 평균 차이는 0.30%p이고 양수 시드는 3/5였으므로 일관된 우위를 주장하기 어렵다. Entropy 대비 평균 차이는 0.51%p이며 다섯 시드에서 모두 양수였다. 다만 이 비교 역시 Holm 보정 후 유의하지 않아, 차이의 크기와 방향을 중심으로 해석하였다.

5.2 클래스별 선택 구성과 탐지 성능

전체 평균 성능의 차이는 모든 결함 클래스에서 같은 방향으로 나타나지 않았다. GC10-DET에서 DINOv2-FF는 Random보다 welding_line의 AP50-95가 11.32%p 높았지만 rolled_pit은 0.96%p 낮았다. NEU-DET에서는 scratches가 3.54%p 높았던 반면 inclusion은 1.37%p, crazing은 1.94%p 낮았다.

표본 선택 방법에 따라 선택된 이미지의 클래스 구성도 달라졌다. GC10-DET의 welding_line을 포함한 이미지는 Random에서 평균 122.4장, DINOv2-FF에서 205.4장이 선택되었다. 반대로 NEU-DET의 rolled-in_scale은 Random에서 74.4장이 선택된 데 비해 DINOv2-FF에서는 32.8장이 선택되었다. scratches는 Random 74.6장, DINOv2-FF 121.2장으로 반대의 차이를 보였다.

이러한 결과는 DINOv2-FF가 클래스별 표본 수를 균형 있게 맞추는 방법은 아니라는 점과 관련된다. DINOv2-FF는 정답 클래스를 이용하지 않고 전체 이미지의 특징 거리를 기준으로 표본을 선택한다. 따라서 같은 클래스에 속한 이미지라도 시각적 변화가 크면 여러 표본이 선택될 수 있고, 반대로 특징이 서로 비슷한 클래스는 상대적으로 적게 선택될 수 있다.

일부 클래스에서는 선택된 이미지 수와 AP의 변화 방향이 일치하였다. welding_line과 scratches는 DINOv2-FF에서 선택 수와 AP가 모두 증가하였고, rolled-in_scale과 waist_folding은 모두 감소하였다. 반면 NEU-DET의 inclusion은 선택 수가 92.8장에서 116.2장으로 증가했으나 AP는 1.37%p 낮았다. GC10-DET의 silk_spot은 선택 수가 180.2장에서 98.0장으로 감소했으나 AP는 1.13%p 높았다. 따라서 선택 수만으로 AP 변화를

설명하기 어렵다. 선택된 이미지의 형태와 난이도 등이 함께 작용했을 가능성은 있으나, 이를 인과적으로 확인한 결과는 아니다.

평균 성능과 취약 클래스 성능의 차이도 관찰되었다. NEU-DET에서 DINOv2-FF의 평균 nAULC는 두 비교 방법보다 높았지만, 최저 클래스 nAULC는 Random보다 1.64%p 낮았고 다섯 시드 중 네 개에서 같은 방향이었다. GC10-DET에서도 최저 클래스 nAULC는 Entropy의 평균이 가장 높았다. 이는 전체 평균의 이점을 각 클래스의 균등한 향상으로 해석할 수 없음을 보여준다.

5.3 Entropy와 Random 비교 결과

본 연구의 Entropy 선택은 두 데이터셋에서 Random보다 낮은 평균 nAULC를 보였다. GC10-DET에서 Entropy는 19.29%, Random은 19.74%였으며, NEU-DET에서는 각각 30.11%, 30.32%였다. 보조 비교의 정확 검정에서 두 차이는 유의하지 않았으므로, 이 결과만으로 Entropy 선택이 일반적으로 열등하다고 해석하기는 어렵다.

Entropy는 현재 탐지 모델이 클래스 구분을 어려워하는 이미지를 선택한다는 점에서 DINOv2-FF와 선택 기준이 다르다. DINOv2-FF가 사전학습된 고정 특징을 이용하는 반면, Entropy는 각 라운드에서 학습된 탐지 모델의 예측 결과를 이용한다. 따라서 두 방법은 서로 다른 정보를 이용해 추가 학습 이미지를 결정한다.

이번 실험에서 Entropy가 Random보다 뚜렷한 평균 성능 향상을 보이지 않은 데에는 사용한 불확실성 정의가 영향을 주었을 가능성이 있다. 본 연구에서는 탐지된 박스의 클래스 점수에 대한 엔트로피를 계산하고 이를 이미지 단위로 평균하였다. 따라서 객체가 아예 검출되지 않은 경우나 경계 상자의 위치가 불확실한 경우는 선택 점수에 충분히 반영되지 않을 수 있다.

Lv 등[5]은 NEU-DET의 네 개 클래스 부분집합에서 마진 기반 불확실성 선택과 클래스별 선택 비율 조정을 결합한 방법이 Random 및 Entropy보다 적은 주석 비율로 목표 성능에 도달하였다고 보고하였다. 본 연구의 Entropy는 이미지 내 예측 박스 엔트로피의 평균만 사용하고 클래스별 선택 비율을 조정하지 않았으며, 탐지 모델과 평가 지표도 다르므로 두 결과를 직접 비교하기는 어렵다.

5.4 특징 기반 다양성 선택의 해석

DINOv2-FF의 결과를 해석할 때에는 특징 공간에서의 다양성과 객체 탐지에 필요한 정보가 완전히 같지는 않다는 점을 고려할 필요가 있다.

본 연구에서는 이미지 전체를 DINOv2-small에 입력하여 얻은 384차원 특징을 사용하였다. 따라서 특징 벡터에는 결함 영역뿐 아니라 이미지의 전체적인 표면 상태와 배경, 결함의 위치 및 크기와 같은 정보가 함께 반영될 수 있다. DINOv2-FF는 이러한 전체 이미지 특징을 기준으로 현재 선택된 집합에서 멀리 있는 이미지를 추가한다.

GC10-DET에서 관찰된 양의 평균 차이는 고정된 실험 조건에서 특징 기반 다양성 선택이 유용할 수 있음을 보여준다. 반면 NEU-DET의 Random 대비 차이는 작고 클래스별 이점과 감소가 함께 나타났다. 특징 공간에서 다양한 이미지를 확보하는 것이 각 결함 클래스에 필요한 학습 정보를 균등하게 확보하는 것과 같지는 않았다.

입력 전처리 역시 특징 공간의 구성에 영향을 줄 수 있다. 본 실험에서는 원본의 가로세로 비율을 유지하면서 긴 변을 518픽셀로 조정하고 나머지 영역을 패딩하는 방식을 사용하였다. 데이터셋마다 원본 이미지의 크기와 비율이 다르기 때문에 동일한 전처리를 사용하더라도 특징 표현에 미치는 영향은 달라질 수 있다.

다만 이번 실험에서는 입력 크기나 전처리 방식만 바꾼 별도의 대조 실험을 수행하지 않았다. 따라서 전처리는 데이터셋 간 결과 차이를 설명할 수 있는 가능한 요인 가운데 하나로 보고, 그 영향은 후속 연구에서 별도로 확인할 필요가 있다.

5.5 연구의 한계와 향후 연구

본 연구에는 다음과 같은 한계가 있다.

첫째, 최종평가셋은 모델 선택과 분리하여 사용하였으나 같은 공개 데이터셋 안에서 구성한 분할이다. 이미지와 연결요소의 분할 간 중복은 제거했지만, 다른 생산 설비나 공정에서 수집한 외부 데이터에 대한 일반화까지 검증한 것은 아니다.

둘째, 반복 실험은 데이터셋별 다섯 개의 선택 시드와 하나의 고정 학습 시드로 수행하였다. 이러한 설계는 초기 라벨 집합과 표본 선택 경로에 따른 변동을 비교하는 데 초점을 두고 있으며, 서로 다른 학습 시드에서 발생하는 모델 학습 변동까지 충분히 평가한 것은 아니다. 특히 다섯 대응쌍을 이용한 정확 양측 부호반전 검정에서는 얻을 수 있는 최소 p값이 0.0625 이므로 통계적 검정력에도 제한이 있다.

셋째, 본 연구의 라벨 예산은 선택된 이미지 수를 기준으로 정의하였다. 한 이미지에 포함된 결함의 수와 경계 상자의 복잡도에 따라 실제 라벨링 시간은 달라질 수 있다. 따라서 동일한 이미지 수에서 얻은 성능 차이를 실제 작업 시간이나 비용의 절감량과 직접 대응시키기 어렵다.

넷째, 실험은 GC10-DET와 NEU-DET의 두 공개 데이터셋과 YOLOv8n, DINOv2-small을 이용한 조건에서 수행하였다. 다른 금속 표면 결함 데이터, 탐지 모델 또는 특징 추출기를 사용할 경우 표본 선택의 결과가 달라질 수 있다. 실제 생산 환경에서 발생하는 조명, 촬영 장비, 제품과 공정의 변화 역시 공개 데이터셋에서는 충분히 반영되지 않을 수 있다.

다섯째, 클래스별 선택 구성과 AP 변화 사이에서 여러 연관이 관찰되었지만, 선택 이미지의 클래스 수만을 통제한 별도의 대조 실험은 수행하지 않았다. 향후에는 클래스 구성을 일정하게 유지하면서 표본의 특징 다양성을 바꾸거나, 전체 이미지 특징과 결함 영역의 특징을 비교하는 실험을 통해 두 요인의 영향을 구분할 수 있다.

후속 연구에서는 학습 시드를 확대하여 모델 학습 과정의 변동을 함께 측정하고, DINOv2 입력 방식과 특징 표현을 달리한 비교를 통해 특징 공간의 영향을 분석할 수 있다. 실제 산업 적용을 고려한다면 외부 생산 환경의 데이터와 이미지 수뿐 아니라 경계 상자 작성 시간 및 검수 시간까지 반영하여 라벨 비용과 탐지 성능의 관계를 평가할 필요가 있다.

VI 결론

본 연구는 소량 라벨 환경에서 사전학습 이미지 특징을 이용한 표본 선택이 금속 표면 결함 객체 탐지 성능에 어떤 영향을 미치는지 확인하였다. 이를 위해 GC10-DET와 NEU-DET를 대상으로 무작위 선택(Random), DINOv2 특징 기반 다양성 선택(DINOv2-FF), 불확실성 기반 선택(Entropy)을 비교하였다. 라벨 이미지는 학습셋의 약 10%에서 35%까지 단계적으로 늘렸으며, 각 단계에서 동일한 조건으로 YOLOv8n을 새로 학습하였다.

최종평가셋에서 GC10-DET의 DINOv2-FF 평균 nAULC는 Random보다 1.47%p, Entropy보다 1.92%p 높았으며 두 비교 모두 다섯 선택 시드에서 차이가 양수였다. NEU-DET에서는 Random 대비 평균 차이가 0.30%p로 작고 시드별 방향이 달랐으며, Entropy 대비 0.51%p의 양의 평균 차이는 다섯 시드에서 모두 관찰되었다. 네 주 비교의 평균 차이 방향은 개발셋에서도 같았으나, 최종평가의 네 주 비교 모두 Holm 보정 후 통계적 유의성은 확인되지 않았다.

클래스별 결과에서는 이점과 감소가 함께 나타났다. GC10-DET의 welding_line과 NEU-DET의 scratches에서는 DINOv2-FF의 평균 AP가 Random보다 높았지만, GC10-DET의 rolled_pit과 NEU-DET의 inclusion·crazing·rolled-in_scale에서는 낮았다. 선택된 이미지의 클래스 구성도 방법에 따라 달랐으며, 선택 수의 변화와 AP 변화의 방향은 모든 클래스에서 일치하지 않았다.

RQ1에 대해 DINOv2-FF는 GC10-DET에서 R1부터 R5까지 Random과 Entropy보다 높은 평균 성능을 보였다. NEU-DET에서는 Random 대비 이점이 작고 시드별 방향이 달랐으며, Entropy 대비로는 작은 양의 차이가 일관되게 관찰되었다. RQ2에 대해서는 평균 성능의 차이가 결함 클래스에 따라 다른 방향으로 나타났고, NEU-DET의 최저 클래스 nAULC는 DINOv2-FF가 두 비교 방법보다 낮았다. 따라서 특징 기반 다양성 선택의 평균적 이점을 모든 클래스와 최저 클래스 성능의 향상으로 일반화할 수 없다.

이 결과는 고정된 학습 시드와 두 공개 데이터셋의 최종평가셋에서 얻은 것이다. 향후에는 학습 시드와 특징 표현을 달리한 반복실험, 외부 생산 환경에서의 평가, 실제 주석 시간을 반영한 비용 분석으로 적용 범위를 확인할 필요가 있다.

참고문헌

[1] Lv, X., Duan, F., Jiang, J.-J., Fu, X., & Gan, L. (2020). Deep Metallic Surface Defect Detection: The New Benchmark and Detection Network. Sensors, 20(6), 1562.
https://doi.org/10.3390/s20061562

[2] Song, K., & Yan, Y. (2013). A noise robust method based on completed local binary patterns for hot-rolled steel strip surface defects. Applied Surface Science, 285, 858-864.
https://doi.org/10.1016/j.apsusc.2013.09.002

[3] Settles, B. (2009). Active Learning Literature Survey. Computer Sciences Technical Report 1648, University of Wisconsin-Madison.
https://research.cs.wisc.edu/techreports/2009/TR1648.pdf

[4] Aghdam, H. H., Gonzalez-Garcia, A., van de Weijer, J., & López, A. M. (2019). Active Learning for Deep Detection Neural Networks. ICCV.
https://openaccess.thecvf.com/content_ICCV_2019/papers/Aghdam_Active_Learning_for_Deep_Detection_Neural_Networks_ICCV_2019_paper.pdf

[5] Lv, X., Duan, F., Jiang, J.-J., Fu, X., & Gan, L. (2020). Deep Active Learning for Surface Defect Detection. Sensors, 20(6), 1650.
https://doi.org/10.3390/s20061650

[6] Oquab, M., et al. (2023). DINOv2: Learning Robust Visual Features without Supervision. arXiv:2304.07193.
https://arxiv.org/abs/2304.07193

[7] Sener, O., & Savarese, S. (2018). Active Learning for Convolutional Neural Networks: A Core-Set Approach. ICLR.
https://arxiv.org/abs/1708.00489

[8] Gupte, S. R., Aklilu, J., Nirschl, J. J., & Yeung-Levy, S. (2024). Revisiting Active Learning in the Era of Vision Foundation Models. Transactions on Machine Learning Research.
https://arxiv.org/abs/2401.14555

[9] Yang, C., Huang, L., & Crowley, E. J. (2024). Plug and Play Active Learning for Object Detection. CVPR.
https://openaccess.thecvf.com/content/CVPR2024/papers/Yang_Plug_and_Play_Active_Learning_for_Object_Detection_CVPR_2024_paper.pdf

[10] Lyu, M., et al. (2023). Box-Level Active Detection. CVPR.
https://openaccess.thecvf.com/content/CVPR2023/papers/Lyu_Box-Level_Active_Detection_CVPR_2023_paper.pdf

[11] Pardo, A., Xu, M., Thabet, A., Arbeláez, P., & Ghanem, B. (2021). BAOD: Budget-Aware Object Detection. CVPR Workshops.
https://openaccess.thecvf.com/content/CVPR2021W/LXCV/papers/Pardo_BAOD_Budget-Aware_Object_Detection_CVPRW_2021_paper.pdf

[12] Lin, T.-Y., et al. (2014). Microsoft COCO: Common Objects in Context. ECCV.
https://arxiv.org/abs/1405.0312

[13] Ultralytics. YOLOv8 model documentation. 공식 소프트웨어 문서. 2026년 9월 23일 확인.
https://docs.ultralytics.com/models/yolov8/

[14] Holm, S. (1979). A Simple Sequentially Rejective Multiple Test Procedure. Scandinavian Journal of Statistics, 6(2), 65–70.
https://www.jstor.org/stable/4615733

[15] Efron, B. (1979). Bootstrap Methods: Another Look at the Jackknife. The Annals of Statistics, 7(1), 1–26.
https://doi.org/10.1214/aos/1176344552

ABSTRACT

Metal Surface Defect Object Detection Using Feature-Based Active Learning under Limited Labeling

Ho Yeol Lee

Department of Data Science

Graduate School of Data Science, Kyungpook National University

Training a metal surface defect detector requires annotations of defect categories and bounding boxes, which are costly to obtain in industrial settings. Active learning selects images for annotation to train models with limited labeled data. This study examined whether sample selection using pretrained DINOv2 image features improves metal surface defect detection under limited labeling.

On GC10-DET and NEU-DET, greedy farthest-first selection using cosine distances between frozen DINOv2-small features (DINOv2-FF) was compared with random selection (Random) and detection-score entropy selection (Entropy). The labeled set increased from approximately 10% to 35% of the training set over five acquisition rounds. YOLOv8n was retrained from the same pretrained weights at each round. Five acquisition seeds and one fixed training seed were used per dataset. All 162 models selected using the development set were evaluated on the held-out test sets. Performance was analyzed using mAP50-95 learning curves, normalized area under the learning curve (nAULC), class-wise AP, and the class composition of selected images.

On GC10-DET, DINOv2-FF had a mean nAULC 1.47 percentage points higher than Random and 1.92 points higher than Entropy; both differences were positive for all five acquisition seeds. On NEU-DET, the mean difference from Random was small (0.30 points), with mixed directions across seeds. The mean difference from Entropy was 0.51 points and was positive for all five seeds. None of the four primary comparisons was statistically significant after Holm correction.

At R5, the DINOv2-FF minus Random AP difference was + 11.32 points for welding_line on GC10-DET and -1.37 points for inclusion on NEU-DET. On NEU-DET, the nAULC formed from the lowest class AP at each round was 1.64 points lower for DINOv2-FF than for Random.

The direction of the mean difference in each of the four primary comparisons observed on the development sets was maintained on the held-out test sets. However, the average benefit of feature-based diversity selection depended on the dataset and did not translate into improvements for every defect class or for worst-class performance.

Keywords: metal surface defects, object detection, active learning, DINOv2, sample selection

부록 A 재현을 위한 실행 조건

이 부록은 본문에서 생략한 구현 세부를 정리한다. 수치표의 단위는 본문과 같다.

표 A-1. 특징 추출과 표본 선택의 세부 조건

항목	값 또는 규칙
특징 모델	facebook/dinov2-small, 동결된 모델. 최종 정규화 CLS에 해당하는 384차원 pooler output.
입력	긴 변 518픽셀로 비율 유지 조정, 중앙 패딩 RGB (124,116,104), crop 없음. uint8 bicubic 및 antialias.
정규화	픽셀을 255로 나눈 뒤 ImageNet 평균 0.485/0.456/0.406, 표준편차 0.229/0.224/0.225 적용.
추출 정밀도	FP32, batch 1, eval 및 inference mode, autocast와 TF32 비활성화.
거리와 동점	L2 단위 벡터의 1−내적. float32 특징을 float64로 읽어 비교. 거리 차이 10^{-12} 이내이면 식별자 오름차순.
Random 난수	PCG64. namespace 1179473458, 데이터셋 코드, 선택 시드, 라운드, 용도를 SeedSequence로 구분.
Entropy	고정 CPU class-aware NMS, 원 anchor index로 클래스 점수 벡터 보존.
이미지 수 변환	n_r=floor([N(10+ 5r)+ 50]/100), r=0,…,5. 추가 수는 이웃 누적 수의 차이.

표 A-2. 학습과 통계의 추가 설정

항목	값 또는 규칙
학습 환경	NVIDIA RTX A4000, Python 3.11.13, PyTorch 2.8.0+ cu128, torchvision 0.23.0+ cu128, CUDA 12.8.
주요 소프트웨어	Ultralytics 8.4.90, transformers 5.13.0.
학습 추가값	workers 4, nbs 64, cos_lr False, box/cls/dfl 7.5/0.5/1.5, HSV 0.015/0.7/0.4.
검증과 보고	학습 중 validation batch 16, 최종 재평가 batch 8.
통계 난수	대응 부트스트랩 100,000회. GC10 seed 2026091912, NEU seed 2026091913.

최종평가는 2026년 9월 25일에 수행하였다. 학습 환경은 표 A-2와 같으며, 최종평가 환경은 표 A-3에 별도로 제시하였다. 두 환경에서 Ultralytics 버전과 평가 조건을 동일하게 유지하였다.

표 A-3. 최종평가 환경과 실행 조건

항목	값 또는 규칙
GPU	NVIDIA GeForce RTX 3070, VRAM 8 GB
Python 및 CUDA	Python 3.11.9, PyTorch CUDA 빌드 12.6
주요 패키지	PyTorch 2.12.1+ cu126, torchvision 0.27.1+ cu126, Ultralytics 8.4.90
성능 평가	imgsz 640, batch 8, conf 0.001, NMS IoU 0.70, max_det 300
추가 평가 설정	workers 4, rect False, seed 2026091900, deterministic True

평가 전 기록된 SHA-256과 162개 과학 실험 모델의 가중치가 모두 일치함을 확인하였다. 데이터셋·선택 시드·방법·라운드의 연결을 검증하였으며 기술 점검용 TECHNICAL_NEU-DET 모델은 제외하였다. 공통 R0는 한 번 평가한 값을 세 방법이 공유하였다.

환경 확인용 개발셋 실행은 GC10-DET의 선택 시드 2026091901, DINOv2-FF R5 모델 하나를 사용하였다. 저장된 개발셋 mAP50-95, mAP50 및 모든 클래스 AP50-95와의 최대 절대 차이는 0이었다. 이는 해당 모델과 개발셋에 대한 평가 일치 확인이며, 모든 모델에서 소프트웨어·GPU 차이의 영향이 없음을 증명한 것은 아니다.

최종평가 결과는 final_test_evaluation_20260925 디렉터리에 보존하였다. raw/results.csv와 results.json에는 모델별 결과를, raw/class_ap.csv에는 클래스별 AP를 기록하였다. raw/runs에는 모델별 결과 JSON, 실행 설정과 로그를 보존하였으며, statistics에는 seed_nAULC.csv, paired_comparisons.csv, 클래스별 결과 및 최저 클래스 분석 파일을 저장하였다. 사전 검증과 고정 프로토콜의 기록은 preflight에 보존하였다.